

SEGMENTAÇÃO DE IMAGEM MÉDICA: ALGORITMOS PARA APLICAÇÃO À CAVIDADE PÉLVICA FEMININA

Patrícia F. Silva, Zhen Ma e João Manuel R. S. Tavares

Faculdade de Engenharia da Universidade do Porto (FEUP) /
Instituto de Engenharia Mecânica e Gestão Industrial (INEGI)
Rua Dr. Roberto Frias 400, 4200-465 Porto, Portugal
{deb10005, zhen.ma, tavares}@fe.up.pt

Palavras chave: Processamento de Imagem, Análise de Imagem, Pavimento Pélvico, Biomecânica.

Resumo

O Processamento e Análise de Imagem compreendem um conjunto de técnicas úteis na melhoria e extracção de informação a partir de imagens. Por exemplo, em Medicina tais técnicas assumem importância relevante no auxílio ao diagnóstico, e em Biomecânica são essenciais na obtenção da geometria das estruturas representadas em tais imagens [1]. O Processamento de Imagem inclui tarefas que permitem melhorar e realçar a informação contidas nas imagens em originais. Por seu lado, a Análise de imagem inclui tarefas para obter informação de mais alto nível a partir das imagens pré-processadas. Uma dessas tarefas de Análise de Imagem é normalmente designada por Segmentação de Imagem. A segmentação de uma imagem consiste na divisão da mesma nas sub-regiões que a constituem, uma tarefa que se realizada manualmente se revela subjectiva, demorada e sujeita a erros [2].

O trabalho em desenvolvimento centra-se no processamento e análise de imagens da cavidade pélvica feminina para estudos biomecânicos de algumas das suas estruturas; nomeadamente, do pavimento pélvico. As desordens ao nível do pavimento pélvico da mulher incluem um conjunto de imposições que afectam mulheres de várias idades, incluindo o prolapso vaginal, a incontinência urinária e fecal, bem como outras anormalidades relacionadas com problemas do sistema urinário e gastrointestinal. Estes problemas comprometem a qualidade de vida das mulheres e representam um grande peso financeiro para o sistema nacional de saúde [3].

A segmentação adequada de imagens da cavidade pélvica representa uma etapa crucial no desenvolvimento de modelos biomecânicos realistas que auxiliem os profissionais de saúde, tanto no apoio à tomada de decisão como no treino destes profissionais e na consequente redução de custos [4-8].

O objectivo deste trabalho consiste em apresentar alguns dos algoritmos de segmentação de imagem médica mais comuns, com enfoque na sua aplicabilidade na segmentação de estruturas da cavidade pélvica de forma a permitir a geração de modelos geométricos adequados para o seu estudo biomecânico.

1. Introdução

O processamento e a análise de estruturas presentes em imagens é uma das áreas da Visão Computacional (VC) com maior potencial e aplicabilidade. Deste modo, o principal objectivo deste trabalho reside na apresentação de várias metodologias computacionais para analisar o comportamento de estruturas em imagens médicas, em particular da cavidade pélvica feminina. A referida análise é fulcral em vários domínios, sendo a medicina um dos mais importantes. Nesta área, a obtenção de algoritmos que permitam uma análise automática da informação contida nas imagens médicas (Ressonância Magnética, Tomografia Computorizada, Ultrassons, entre outras), torna-se fundamental para compreender o funcionamento e o comportamento das diversas estruturas e, deste modo, para melhor assistir os médicos na prestação de cuidados de saúde. Para além disto, também se torna uma mais-valia para aumentar o realismo em simulações computacionais de órgãos humanos e, assim, no caso da cavidade pélvica feminina, ajudar ao diagnóstico das doenças associadas, às intervenções a realizar, e para maior entendimento dos mecanismos fundamentais de disfunções urogenitais, bem como o seu tratamento. No entanto, o desenvolvimento de metodologias completamente automáticas para tais fins continua a constituir um grande desafio devido, entre outras causas, à quantidade de dados envolvidos, à variabilidade das formas que as estruturas em estudo podem assumir, e a questões relacionadas com a qualidade das imagens. Em particular, pode-se destacar o ruído e os problemas de amostragem que podem degradar os resultados obtidos através das técnicas tradicionais de segmentação de imagem, que consideram apenas informação local, o que implica frequentemente a necessidade de intervenção humana.

De uma maneira geral, a eficiência dos algoritmos de segmentação de imagem está vinculada à extracção automática das estruturas de interesse. Neste sentido, os métodos são adaptados à aplicação em causa, sendo que não existem algoritmos de segmentação convenientes a todos os tipos de aplicação.

Neste trabalho, apresenta-se uma revisão de algoritmos de segmentação, que estão divididos tendo em conta as suas principais características: de *threshold*, de *clustering* e modelos deformáveis.

2. Algoritmos de Segmentação

2.1. Algoritmos de *threshold*

O *threshold* global (sendo o método de Otsu o mais generalizado [9], e que se exemplifica na Figura 2), é simples e computacionalmente rápido. Baseia-se no pressuposto que uma imagem pode ser representada por um histograma bimodal e, consequentemente, pode-se obter a estrutura de interesse com uma simples operação que compara os valores da imagem com o valor definido para *threshold*.

Supondo que se tem uma imagem $f(x, y)$ com o histograma apresentado na Figura 1, o resultado de um algoritmo de *threshold* global de valor T é dado por:

$$g(x, y) = \begin{cases} 1 & \text{if } (x, y) > T \\ 0 & \text{if } (x, y) \leq T \end{cases} \quad (1)$$

Assim, como resultado final, obtém-se uma imagem onde os valores “1” correspondem à estrutura a segmentar e os valores “0” ao fundo da imagem.





Figura 1 – Exemplo de um histograma bimodal.



a)



b)



c)

Figura 2 – Imagem de ultrassom da cavidade pélvica de uma paciente a); Resultado da utilização de um algoritmo de *threshold* global (método de Otsu) com um *threshold* de 0.3176 b); Resultado da utilização de um *threshold* global igual a 0.17 c).

Existem várias formas para escolher o valor de *threshold* global a usar na segmentação e, para além disso, existem métodos baseados em *threshold* locais (ou adaptativos). De facto, por vezes não é possível definir um valor de *threshold* global para produzir uma boa segmentação em toda a imagem. Por exemplo, quando o fundo da imagem a segmentar não é constante ou quando existem variações de contrastes ao longo da imagem, algo que acontece frequentemente em imagens médicas, que geralmente possuem baixos contrastes e contornos difusos. Nestes casos, um algoritmo de *threshold* global pode resultar com sucesso em certas zonas da imagem mas não em outras áreas da mesma imagem. Uma solução para este problema é aplicar *thresholds* locais, que podem ser determinados dividindo a imagem original em várias áreas (sub-imagens) e calculando um valor de *threshold* específico para cada uma dessas áreas. Outra forma de determinar os valores de *threshold* local é examinando as intensidades da imagem na vizinhança de cada pixel e seleccionar o valor de *threshold* local como a média da distribuição das intensidades locais, ou outro valor estatístico, tal como a média somada ao desvio padrão, a média dos valores máximos e mínimos, ou outros que se baseiem no gradiente local de intensidades [10].

Dependendo da informação usada para definir os valores de *threshold* local, os algoritmos também podem ser posteriormente classificados como: baseados em contornos, baseados em regiões e híbridos.

2.1.1 Algoritmos baseados em regiões

A ideia de algoritmos baseados em regiões provém do conceito de que as características quantificáveis dentro de uma estrutura tendem a ser homogéneas. A título de exemplo, uma abordagem simples passa por escolher um pixel, ou grupo de pixéis (chamados sementes) e fundir os pixéis vizinhos cuja intensidade, ou outra propriedade, seja semelhante [10]. Basicamente, se houver dois pixéis adjacentes similares, são agrupados numa única região. Se duas regiões adjacentes são suficientemente semelhantes, colectivamente, então são agrupadas numa só região. A selecção da característica usada para a escolha dos vizinhos a serem adicionados à região da semente inicial, ou seja, o critério de similaridade, depende do problema em questão e das características da imagem a segmentar, como por exemplo, se a imagem é em tons de cinzento ou a cores [11]. Em princípio, este tipo de métodos converge quando não há mais fusões possíveis [12].

A vantagem de um método de *region growing* é ser capaz de segmentar correctamente as regiões que possuem propriedades semelhantes e estão separadas espacialmente, gerando regiões interligadas [10]. A sua principal desvantagem é que usualmente requer intervenção manual para obter o ponto inicial de colocação das sementes. Assim, é necessário colocar uma semente para cada região a segmentar. Uma outra desvantagem prende-se com o facto de sementes colocadas em regiões iniciais diferentes poderem originar segmentações distintas para uma mesma imagem [12].

Um exemplo da aplicação deste tipo de algoritmos à segmentação de imagens da cavidade pélvica é apresentado em [13].

2.1.2 Algoritmos baseados em contornos

Uma borda (ou contorno) é o limite ou fronteira entre duas regiões com propriedades relativamente distintas numa imagem. A sua detecção baseia-se na determinação dos pontos em que a intensidade muda repentinamente. Mudanças repentinas em imagens, geralmente reflectem eventos importantes na cena, como a descontinuação da profundidade (transição entre a estrutura e o fundo), descontinuação da orientação de uma superfície, mudança das propriedades do material ou variações na iluminação da cena.

Os algoritmos baseados em contornos caracterizam-se, então, pela determinação do gradiente de intensidade [10]. Este gradiente, usado em vários algoritmos para detectar contornos em imagens, resulta da primeira derivação da função da imagem. Assim sendo, para uma determinada imagem $f(x, y)$ pode-se calcular a magnitude do seu gradiente de intensidade como sendo:

$$|G| = \sqrt{G_x^2 + G_y^2} = \sqrt{\left[\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2\right]}, \quad (2)$$

sendo a direcção do gradiente dada por:

$$D = \tan^{-1}\left(\frac{G_y}{G_x}\right), \quad (3)$$

em que G_x e G_y representam os gradientes nas direcções x e y , respectivamente.

Alguns dos algoritmos mais conhecidos que se incluem nesta categoria são, por exemplo, o de Prewitt [14], de Roberts, de Sobel [14] (Figura 3a), o Laplaciano [15] (Figura 3b) e o de Canny [16] (Figura 3c). Por exemplo, o algoritmo Laplaciano usa a informação retirada pela segunda derivada do gradiente da imagem [15]. Por sua vez, o algoritmo de Canny, um dos mais completos e mais utilizados em Visão Computacional, é um filtro de convolução que usa a primeira derivada. Inicialmente, suaviza o ruído e, posteriormente, localiza as bordas combinando um operador diferencial com um filtro Gaussiano [16].

Uma das vantagens dos métodos de detecção de bordas prende-se com o facto de serem computacionalmente rápidos e não necessitarem de informação prévia sobre o conteúdo da imagem. Por outro lado, possuem as desvantagens de serem muito sensíveis a ruídos e de, frequentemente, não conseguirem delimitar correctamente toda a imagem, gerando linhas descontínuas e com falhas. Deste modo, torna-se necessário aplicar posteriormente outras técnicas de processamento à imagem resultante, pelo que estes métodos são raramente usados de forma independente, mas sim como uma etapa de pré processamento em técnicas de segmentação mais complexas [4].



Figura 3 – Resultado do operador de Canny na imagem da Figura 2a a); Resultado do operador de Sobel na imagem da Figura 2a b); Resultado do operador de Laplaciano na imagem da Figura 2a c).

2.1.3 Algoritmos Híbridos

A informação usada pelos algoritmos híbridos combina diferentes propriedades da imagem original para realizar a segmentação. Exemplos típicos destes algoritmos híbridos são os algoritmos de *watershed*, ou divisor de águas, que combinam a técnica baseada em regiões com algoritmos de contornos (como, por exemplo, os descritos em [17], [18] e [19])

A transformada *watershed* propõe uma abordagem morfológica para o problema de segmentação de imagem, interpretando as imagens a segmentar como superfícies onde cada pixel corresponde a uma posição, e os níveis de cinza de cada pixel determinam as altitudes. Existem várias soluções para realizar a segmentação por *watershed*, mas todas utilizam o mesmo conceito básico: comparando uma imagem a uma superfície topográfica, pode-se “inundá-la” a partir das suas regiões interiores. Dessa maneira, secciona-se a imagem original em diferentes conjuntos: as bacias hidrográficas e as linhas divisoras de águas [20].

Por combinar diversas informações da imagem original, estes algoritmos são bastante satisfatórios, mas tendem a apresentar problemas de sobre-segmentação, especialmente em imagens com muito ruído [4].

2.2 Algoritmos baseados em técnicas de Clustering

Uma vez que as estruturas em imagens médicas podem ser tratadas como padrões, técnicas de reconhecimento de padrões também têm vindo a ser utilizadas para segmentação de tais estruturas, sendo assim comumente utilizadas em imagens médicas [4].

Neste domínio, podem ser referidos os métodos de classificação supervisionados e os métodos não supervisionados, para detecção de aglomerados (*clustering*) e reconhecimento de padrões (*pattern recognition*). Os primeiros são supervisionados uma vez que podemos providenciar amostras de treino para serem classificadas. Pelo contrário, os algoritmos não supervisionados pressupõem que o sistema tente encontrar por si só a informação necessária, não utilizando nenhum conhecimento prévio sobre as estruturas a segmentar [12].

Alguns dos algoritmos de classificadores supervisionados mais utilizados são: os classificadores *k-nearest neighbour* (kNN) [21], os algoritmos *maximum likelihood* (ML) [22], as *artificial neural networks* (ANN) [23] com supervisão, as *support vector machines* (SVM) [23], os *active shape models* (ASM) [23] e os *active appearance models* (AAM) [23].

As técnicas de classificação não supervisionada, usualmente denominadas por técnicas de *clustering*, incluem algoritmos como: o *fuzzy K-means* (FKM) [24], o ISODATA [24] e as *unsupervised neural networks* [10].

Os algoritmos baseados em técnicas de *clustering* têm vindo a ser aplicados na segmentação dos músculos pélvicos (*levator ani*) [4], que é necessária para uma posterior reconstrução 3D da cavidade pélvica de forma realista [4].

2.3 Algoritmos de Modelos Deformáveis

A segmentação de contornos baseada em modelos deformáveis tem sido frequentemente considerada como um dos maiores sucessos da Visão Computacional nas últimas décadas. A imagem médica tem sido um dos campos em que a sua aplicação se revelou mais fértil, uma vez que têm sido extensivamente aplicados na segmentação de imagens médicas (2D, 3D e 4D), com resultados promissores [25]. Comparados com os tipos de métodos anteriores, os algoritmos baseados em modelos deformáveis são mais flexíveis e podem ser usados para segmentações mais complexas [25].

A maioria das estratégias usadas por este tipo de modelos passa pela optimização de funções objectivo, procurando encontrar um compromisso entre um termo de energia baseado na imagem e outro termo relacionado com uma energia interna ou modelo de forma (tipicamente, a suavidade de pontos adjacentes). Uma alternativa aos modelos baseados na optimização de uma função objectivo, consiste em formular a deformação de um contorno como uma frente de onda

que se propaga, que pode ser considerada como uma iso-linha de uma função envolvente [25]. Os fundamentos matemáticos deste tipo de modelos podem ser encontrados em [10, 26]. Pode-se então dividir os modelos deformáveis em dois sub-tipos: modelos paramétricos e modelos geométricos.

2.3.1. Modelos Deformáveis Paramétricos

Os modelos deformáveis paramétricos podem ser vistos como um caso especial de uma técnica mais geral de ajustar um modelo deformável a uma imagem por minimização de energia. Estes modelos necessitam de ter um início próximo do contorno desejado e, posteriormente, a *snake* (ou o contorno activo, o mais conhecido entre os algoritmos paramétricos) é impelida a deslocar-se em direcção a uma solução apropriada de segmentação [25]. A partir disto, pode-se facilmente apurar as desvantagens deste método: o facto de ser sensível aos valores iniciais e de ser fraco para aplicação em estruturas com curvaturas elevadas.

A formulação matemática original correspondente aos contornos activos pode ser encontrada em [27]. As *snakes* podem ser definidas como curvas modeladas no domínio da imagem, que se deslocam sob a influência de forças internas (definidas pela própria curva) e forças externas calculadas a partir da imagem original [24]. As primeiras mantêm o modelo suave durante a deformação, enquanto as últimas fazem o modelo mover-se em direcção às fronteiras da estrutura de interesse na imagem. O funcional de energia a minimizar é uma combinação das forças referidas, sendo uma *snake* definida parametricamente como $v(i) = [x(i), y(i)]$, em que $x(i)$ e $y(i)$ são as coordenadas x , y ao longo do contorno. O funcional de energia a minimizar pode ser escrito como [12]:

$$E_{snake} = \sum_{i=1}^N [E_{int}(i) + E_{ext}(i)], \quad (4)$$

em que E_{int} e E_{ext} representam, respectivamente, a energia interna da *snake* e as forças externas de restrição, e N é o número total de pontos da *snake*.

A energia interna da *snake* pode ser expressa como:

$$E_{int}(i) = \alpha_i \|v_i - v_{i-1}\|^2 + \beta_i \|v_{i-1} - 2v_i + v_{i+1}\|^2, \quad (5)$$

em que α_i e β_i especificam a rigidez e a elasticidade da *snake*. O primeiro termo faz o modelo assumir um comportamento rígido. Quanto mais elevado for este valor, mais curto será o contorno obtido. O segundo parâmetro confere-lhe um comportamento elástico.

As *snakes* são consideradas activas uma vez que se minimiza o funcional de energia, levando-as a exibir um comportamento dinâmico [27] e [28], permitindo, não só a detecção de contornos, mas também o seguimento do seu movimento, o que pode revelar-se extremamente útil em casos de estudo da cavidade pélvica como o apresentado em [29], no qual a segmentação foi toda efectuada manualmente. Existem diversos algoritmos de *snakes*, sendo um deles o proposto por [30], que assume que uma imagem consiste num número finito de regiões,

caracterizadas por um conjunto pré-determinado de características, tais como a média ou a textura, que podem ser inferidas a partir dos dados da imagem. Um exemplo de uma aplicação deste algoritmo a imagens de ultrassons da cavidade pélvica pode ser visto na Figura 4.

Um outro exemplo de razoável sucesso na implementação de *snakes* na área médica, nomeadamente para detecção automática de estruturas no cérebro em imagens de PET (Tomografia por Emissão de Positrões) está descrito em [31].




Figura 4 – Zona de inicialização e resultado da aplicação de uma *snake* após 1000 iterações para segmentar a bexiga a); Zona de inicialização e resultado da aplicação de uma *snake* após 1000 iterações, para segmentar a junção ano-rectal b); Zona de inicialização e resultado da aplicação de uma *snake* após 1000 iterações, para segmentação da sínfise púbica c).

2.3.2 Modelos Deformáveis Geométricos

Os modelos geométricos, ou *level set*, constituem uma alternativa aos modelos baseados na optimização de uma função objectivo, sendo a deformação do contorno formulada como uma frente de onda que se propaga e que é considerada como um *level set* de valor zero de uma função envolvente. Esta função envolvente pode ser expressa na forma de uma equação diferencial parcial, em que um termo de velocidade força a paragem da propagação de acordo com

informação obtida a partir da imagem a segmentar. Exemplos de definição de funções de velocidade podem ser encontrados em [32] e [33]. Assim sendo, este processo de segmentação incorpora uma curva inicial que é o *level set* de nível zero de uma superfície de dimensão superior, e faz evoluir essa superfície de modo a que esse *level set* vá convergir para a estrutura a segmentar. Uma propriedade útil desta abordagem é o facto da função *level set* se manter válida mesmo quando a curva altera a sua topologia, o que representa uma vantagem em relação aos modelos paramétricos. No entanto, a facilidade de adaptação da topologia, útil em muitas aplicações, pode por vezes conduzir a resultados indesejáveis, produzindo formas com topologia não consistente com a da estrutura a detectar. Os avanços nesta área tiveram a sua origem em [34] e têm sido aplicados a imagem médica por vários autores, como em [35], [36] e [37]. Um exemplo de aplicação à cavidade pélvica pode ser visto na Figura 5, onde se utilizou o algoritmo de Chan-Vese [33] para efectuar a segmentação de diferentes órgãos da cavidade pélvica.




Figura 5 - Zona de Inicialização e resultado da aplicação do algoritmo de Chan-Vese, após 1000 iterações, para segmentar a bexiga a); Zona de Inicialização e resultado da aplicação do algoritmo de Chan-Vese, após 300 iterações, para segmentar a junção ano-rectal b); Zona de

inicialização e resultado da aplicação do algoritmo de Chan-Vese, após 800 iterações, para segmentação da sínfise púbica c).

3. Conclusões

A crescente importância da imagiologia médica no diagnóstico e tratamento de doenças, abriu um conjunto de desafios centrados na computação de modelos geométricos precisos de estruturas anatómicas a partir de imagens médicas.

A segmentação automática de estruturas em imagens médicas constitui actualmente um desafio, devido a factores como o tamanho dos conjuntos de dados envolvidos, a complexidade e variabilidade das estruturas a segmentar e outros inerentes às limitações típicas dos dados utilizados.

Existe um grande número de algoritmos de segmentação de imagem para detecção de tais estruturas, e todos eles possuem, de uma forma ou de outra, variadas aplicações na área médica. Contudo, os modelos de contornos activos e, especialmente, os modelos de *level set*, são os mais completos e os que usualmente produzem melhores resultados de segmentação.

A investigação nesta área prossegue, procurando-se obter algoritmos cada vez mais robustos à interferência de ruído e a problemas de inicialização, e que permitam uma segmentação inteiramente automática, minimizando assim a interferência do utilizador.

6. Agradecimentos

Este trabalho foi desenvolvido no âmbito do projecto “Metodologias para Análise de Órgãos a partir de Imagens Médicas Complexas – Aplicações à Cavidade Pélvica Feminina”, com a referência PTDC/EEA-CRO/103320/2008, financiado pela Fundação para a Ciência e a Tecnologia (FCT).

Referências

1. F. Alexandre, R.M.N. Jorge, R.E. Sayed, T. Mascarenhas e A.A. Fernandes, *Obtenção de Modelos Sólidos de Órgãos da Cavidade Pélvica da Mulher*, in *Encontro Nacional de Visualização Científica*. Setembro, 2005.
2. D.J. Withey e Z.J. Koles, *Medical Image Segmentation: Methods and Software*, in *International Conference on Functional Biomedical Imaging*. 2007. p. 140-143.
3. S. Rahmanian, R. Jones, Q. Peng e C.E. Constantinou, *Visualization of Biomechanical Properties of Female Pelvic Floor Function Using Video Motion Tracking of Ultrasound Imaging*. Studies in Health Technology and Informatics 2008: p. 132:390-395.
4. Z. Ma, R.N. Jorge, T. Mascarenhas e J.M.R.S. Tavares, *A review of algorithms for medical image segmentation and their applications to the female pelvic cavity*. Computer Methods in Biomechanics and Biomedical Engineering, 2010. **13**(2): p. 235-246.
5. S. Vasilache e K. Najarian, *Automated Bone Segmentation from Pelvic CT Images*, in *IEEE International Conference on Bioinformatics and Biomedicine Workshops*. 2008.

6. Q. Peng, R. Jones, K. Shishido e C.E. Constantinou, *Ultrasound Evaluation of Dynamic Responses of Female Pelvic Floor Muscles*. *Ultrasound Med Biol* 2007. **33**(3): p. 342-352.
7. N. Morakkabati-Spitz, J. Gieseke, W.A. Willinek, P.J. Bastian, B. Schmitz, F. Träber, U. Jaeger, S.C. Mueller, and H.H. Schild, *Dynamic pelvic floor MR imaging at 3 T in patients with clinical signs of urinary incontinence-preliminary results*. *Eur Radiol*, 2008. **18**: p. 2620-2627.
8. T.R. Mackel, J. Rosen e C.M. Pugh, *Markov Model Assessment of Subjects' Clinical Skill Using the E-Pelvis Physical Simulator*. *IEEE Transactions on Biomedical Engineering* 2007. **54**(12): p. 2133-2141.
9. N. Otsu, *A threshold selection method from gray-level histograms*. *IEEE Trans Syst Man Cybern*, 1979. **9**(1): p. 62-66.
10. I.N. Bankman, ed. *Handbook Medical Imaging Processing Analysis*. 2000, Academic Press: San Diego/London.
11. R.C. Gonzalez, R.E. Woods e S.L. Eddins, *Digital Image Processing Using MATLAB*. 2003, New Jersey: Prentice-Hall.
12. J. Suri, D.L. Wilson e S. Laxminarayan, eds. *Handbook of Biomedical Image Analysis*. Vol. 2. 2005, Kluwer Academic/ Plenum Publishers: New York.
13. D. Pasquier, T. Lacorniere, M. Vermandel, J. Rousseau, E. Lartigau e N. Betrouni, *Automatic Segmentation of Pelvic Structures from Magnetic Resonance Images for Prostate Cancer Radiotherapy*. *International Journal of Radiation Oncology Biol. Phys*, 2007. **68**(2): p. 592-600.
14. N. Senthilkumaran e R. Rajesh, *Edge Detection Techniques for Image Segmentation – A Survey of Soft Computing Approaches*. *International Journal of Recent Trends in Engineering*, 2009.
15. L.S. Davis, *A survey of edge detection techniques*. *Computer Graphics and Image Processing*, 1975. **4**(3): p. 248-270.
16. J. Canny, *A computational approach to edge detection*. *IEEE Trans Pattern Anal Mach Intell*, 1986. **8**(6): p. 679-698.
17. S. Beucher e C. Lantuéjoul. *Use of watersheds in contour detection*. in *International Workshop on Image Processing, Real-Time Edge and Motion Detection/Estimation*. 1979. Renne.
18. L. Vincent e P. Soille, *Watersheds in digital spaces: an efficient algorithm based on immersion simulations*. *IEEE Trans Pattern Anal Mach Intell*, 2001. **13**(6): p. 583-598.
19. G. Hamarneh e X.X. Li, *Watershed segmentation using prior shape and appearance knowledge*. *Image Vis Comput*, 2009. **27**(1): p. 59-68.
20. A. Körbes e R.A. Lotufo. *Análise de Algoritmos da Transformada Watershed*. in *17th International Conference on Systems, Signals and Image Processing*. 2010.
21. H.A. Vrooman, C.A.C. CA, R. Stokking, I.M. Arfan, M.W. Vemooij, M.M. Breteler, and W.J. Niessen, *KNN-based multi-spectral MRI brain tissue classification: manual training versus automated atlas-based training*. *SPIE Medical Imaging*, 2006.
22. A. Sarti, C. Corsi, E. Mazzini e C. Lamberti, *Maximum likelihood segmentation of ultrasound images with Rayleigh distribution*. *IEEE Trans Ultrason Ferroelect Freq Control*, 2005. **52**(6): p. 947-960.
23. M. James, *Classification algorithms*. 1985, NY: Wiley-Interscience.
24. M.A. Jacobs, R.A.K. RA, H. Soltanian-Zadeh, Z.G.Z. ZG, A.V. Goussev, D.J. Peck, J.P. Windham, and M. Chopp, *Unsupervised segmentation of multiparameter MRI in experimental cerebral ischemia with comparison to T2, diffusion, and ADC MRI parameters and histopathological validation*. *JMRI*, 2000. **11**(4): p. 425-437.
25. J.S. Silva, B.S. Santos, A. Silva e J. Madeira, *Modelos Deformáveis na Segmentação de Imagens Médicas: uma introdução*. *Revista do DETUA*, 2004. **4**(3).
26. C. Xu, D.L. Pham e J.L. Prince. *Image Segmentation Using Deformable Models*. 1999.
27. M. Kass, A. Witkin e D. Terzopoulos, *Snakes: Active Contour Models*. *International Journal of Computer Vision*, 1988: p. 321-331.
28. R. Uppaluri, E.A. Hoffman, M. Sonka, P.G. Hartley, G.W. Huuninghake e G. McLennan, *Computer Recognition of Regional Lung Disease Patterns*. *American Journal of Respiratory and Critical Care Medicine*, 1999. **160**: p. 648-653.
29. S. Rahmanian, R. Jones, Q. Peng e C.E. Constantinou, *Visualization of Biomechanical Properties of Female Pelvic Floor Function Using Video Motion Tracking of Ultrasound Imaging*. *Medicine Meets Virtual Reality*, 2008. **16**.
30. A.Y. Jr., A. Andy e A. Willsky. *The Proceedings of the Seventh IEEE International Conference on Computer Vision*. 1999.
31. A. Gjedde, S.B. Hansen, G. Knudsen e O.B. Paulson, eds. *Physiological Imaging of the Brain with PET*. 2001, Academic Press, San Diego. 39-43.
32. R. Malladi, J.A. Sethian e B. Vemuri. *A topology independent shape modeling scheme*. in *SPIE - Conference on Geometric Methods in Computer Vision*. 1993.
33. T.F. Chan e L.A. Vese, *Active contour without edges*. *IEEE Trans Image Process*, 2001. **10**: p. 266-277.
34. S. Osher e J.A. Sethian, *Fronts Propagation with Curvature Dependent Speed: Algorithms Based on Hamilton-Jacobi Formulations*. *Journal of Computational Physics*, 1988. **79**: p. 12-49.
35. D. Jayadevappa, S.S. Kumar e D.S. Murty, *A New Deformable Model Based on Level Sets for Medical Image Segmentation*. *IAENG International Journal of Computer Science*, 2009. **36**(3).
36. J. Schmid e N. Magnenat-Thalmann. *MRI Bone Segmentation Using Deformable Models and Shape Priors*. in *Medical Image Computing and computer-assisted intervention: MICCAI*. 2008. New York.
37. Z. Ma, R.N. Jorge, T. Mascarenhas e J.M.R.S. Tavares, *Novel Approach to Segment the Inner and Outer Boundaries of the Bladder Wall in T2-weighted Magnetic Resonance Images*. *Annals of Biomedical Engineering* (in press), 2011.